Universidade Federal de Uberlândia

Aula Prática - 08

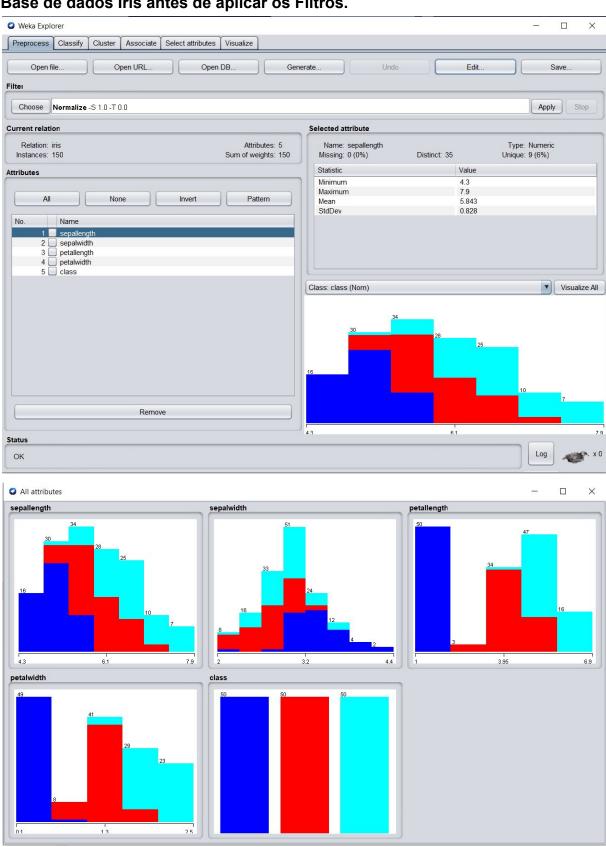
Pedro Henrique Faria Teixeira - 11621BCC025

João Daniel de Aquino Rufino - 11621BCC033

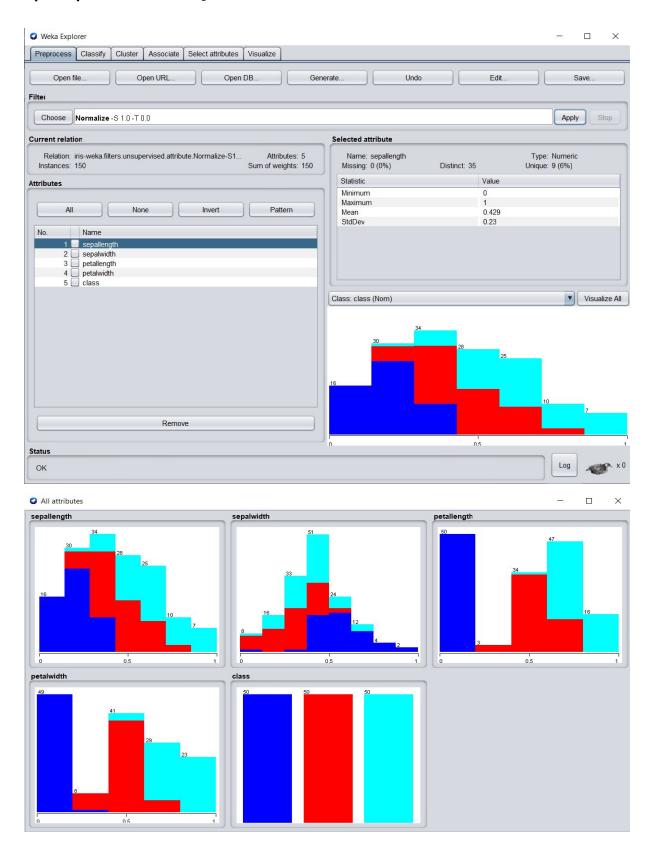
Agrupamento de Dados

01 - Iris

Base de dados Iris antes de aplicar os Filtros.

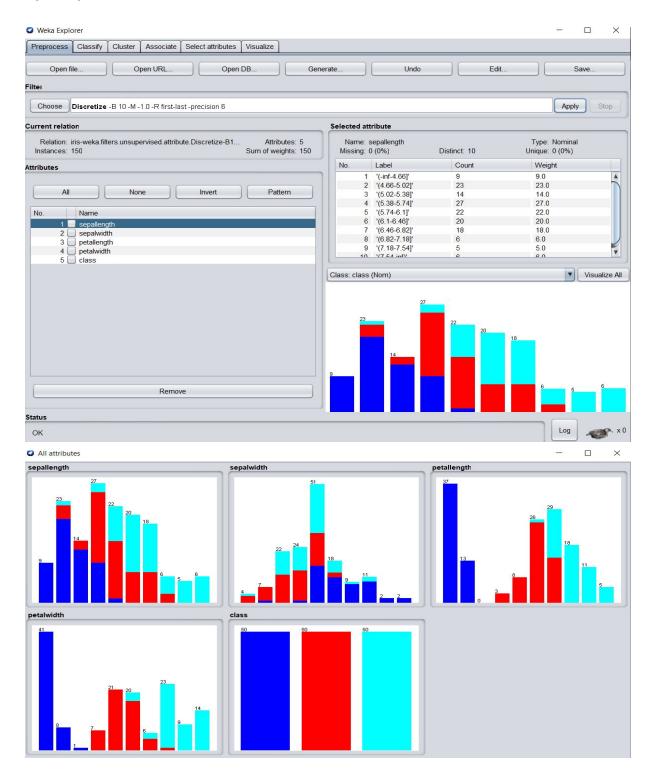


Após aplicar Normalização.



- Podemos observar que tivemos os dados mais bem distribuídos quando nos atentamos para os atributos, máximo, mínimo e média. Graficamente não se alterou.

Após aplicar Discretização:



 Podemos observar que os dados foram discretizados, tendo uma maior limitação dos valores, graficamente separados em stacked bars. Quando olhamos para a coluna sepallength podemos observar claramente como os dados foram discretizados

02 - Diabetes Base de dados antes de aplicar os filtros



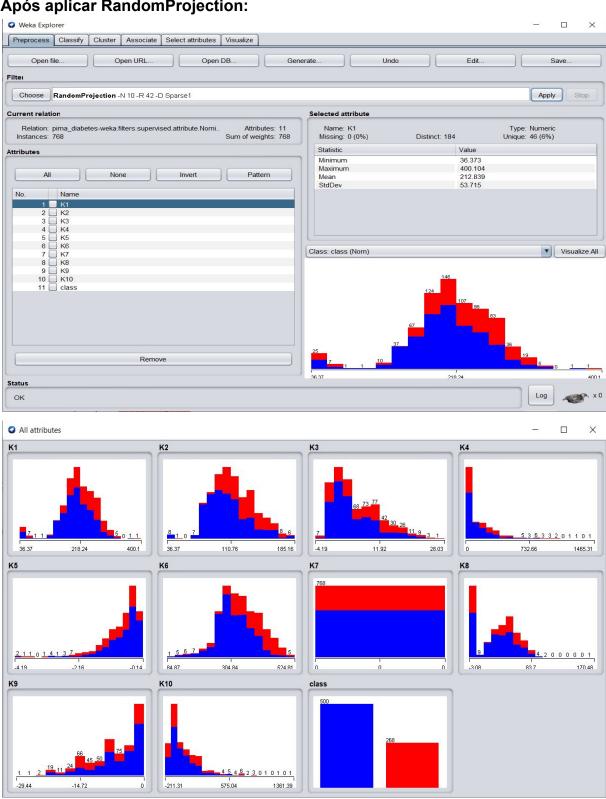
Após aplicar PKIDiscretize:



- Podemos observar que os dados foram discretizados, tendo uma maior limitação dos valores, graficamente separados em stacked bars. Quando olhamos para a coluna preg podemos observar claramente como os dados

foram discretizados, usando outra algoritmo de discretização porém chegando a um resultado semelhante ao usado na base de dados Iris

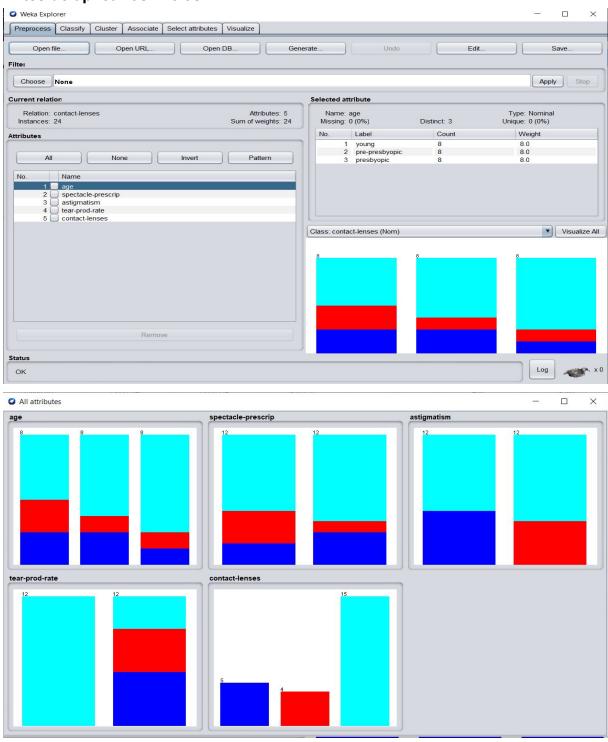
Após aplicar RandomProjection:



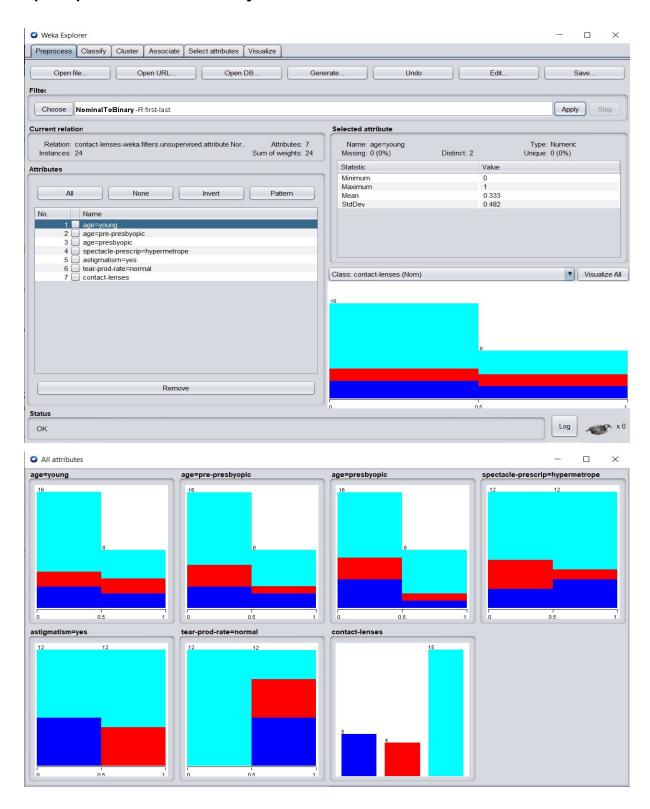
 Pode-se observar que houve uma redução na dimensionalidade dos dados, ou seja diminui-se também os valores contidos no dataset, deixando-o mais limpo. Fica bem visível essa mudança graficamente.

03 - Contact Lenses

Antes de aplicar os Filtros:



Após aplicar NominalToBinary



 Podemos observar que houve uma binarização dos dados, trocando até mesmo os nomes das colunas, graficamente observa se que houve uma variável que se estendeu mais dos que as outras justamente por se encaixar melhor no atributo nominal.

Após aplicar OrdinalToNumeric:



- Podemos observar que houve uma troca de valores na base de dados e houve uma variável que se expandiu novamente por se encaixar melhor ao filtro.

1 - d)

Kmeans - Iris - 3 clusters

```
=== Run information ===
```

Scheme: weka.clusterers.SimpleKMeans -init 0 -max-candidates 100 -periodic-pruning 10000 -min-density 2.0 -t1 -1.25 -t2 -1.0 -N 3 -A "weka.core.EuclideanDistance -R first-last" -I 500 -num-slots 1 -S 10

weka.core.EuclideanDistance -R first-last -1 500 -fluin-slots 1 -5 1

Relation: iris-weka.filters.unsupervised.attribute.Remove-R5

Instances: 150
Attributes: 4
sepallength
sepalwidth
petallength

petalwidth

Test mode: evaluate on training data

=== Clustering model (full training set) ===

kMeans

=====

Number of iterations: 6

Within cluster sum of squared errors: 6.998114004826762

Initial starting points (random):

Cluster 0: 6.1,2.9,4.7,1.4 Cluster 1: 6.2,2.9,4.3,1.3 Cluster 2: 6.9,3.1,5.1,2.3

Missing values globally replaced with mean/mode

Final cluster centroids:

Cluster#

Attribute	Full Dat	ta ()	1	2
	(150.0)	(61.0)	(5	50.0)	(39.0)

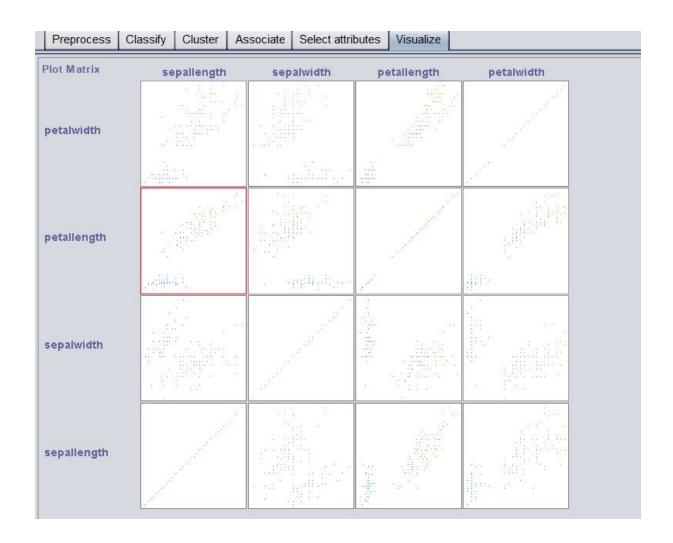
sepallength	5.8433	5.8885	5.006	6.8462
sepalwidth	3.054	2.7377	3.418	3.0821
petallength	3.7587	4.3967	1.464	5.7026
petalwidth	1.1987	1.418	0.244	2.0795

Time taken to build model (full training data): 0.01 seconds

=== Model and evaluation on training set ===

Clustered Instances

- 0 61 (41%)
- 1 50 (33%)
- 2 39 (26%)



Kmeans - Diabetes - 2 Clusters

=== Run information ===

Scheme: weka.clusterers.SimpleKMeans -init 0 -max-candidates 100 -periodic-pruning 10000 -min-density 2.0 -t1 -1.25 -t2 -1.0 -N 2 -A "weka.core.EuclideanDistance -R first-last" -I 500 -num-slots 1 -S 10

Relation: pima_diabetes-weka.filters.unsupervised.attribute.Remove-R9

Instances: 768
Attributes: 8
preg
plas

pres skin insu mass pedi age

Test mode: evaluate on training data

=== Clustering model (full training set) ===

kMeans

=====

Number of iterations: 7

Within cluster sum of squared errors: 121.2579017999101

Initial starting points (random):

Cluster 0: 1,126,56,29,152,28.7,0.801,21 Cluster 1: 8,95,72,0,0,36.8,0.485,57

Missing values globally replaced with mean/mode

Final cluster centroids:

Cluster#

Attribute Full Data 0 1 (768.0) (515.0) (253.0)

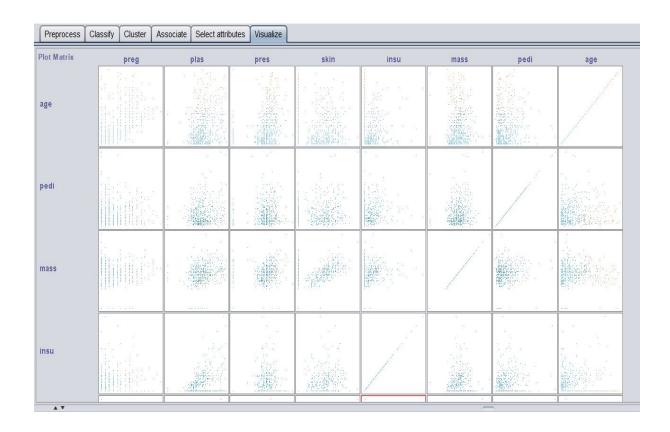
_____ 3.8451 2.0835 7.4308 preg 120.8945 115.3282 132.2253 plas 69.1055 65.9903 75.4466 pres skin 20.5365 21.8194 17.9249 insu 79.7995 85.0194 69.1739 31.9926 31.7751 32.4352 mass 0.4719 0.4708 0.4741 pedi 33.2409 26.7728 46.4071 age

Time taken to build model (full training data): 0.05 seconds

=== Model and evaluation on training set ===

Clustered Instances

- 0 515 (67%)
- 1 253 (33%)



Kmeans - Glass - 4 Clusters

=== Run information ===

Scheme: weka.clusterers.SimpleKMeans -init 0 -max-candidates 100 -periodic-pruning 10000 -min-density 2.0 -t1 -1.25 -t2 -1.0 -N 4 -A "weka.core.EuclideanDistance -R first-last" -I 500 -num-slots 1 -S 10 Relation: Glass-weka.filters.unsupervised.attribute.Remove-R10

```
Instances: 214
Attributes: 9
       RΙ
       Na
       Mg
       Αl
       Si
       Κ
       Ca
       Ba
       Fe
Test mode:
           evaluate on training data
=== Clustering model (full training set) ===
kMeans
=====
Number of iterations: 8
Within cluster sum of squared errors: 26.28430433007474
Initial starting points (random):
Cluster 0: 1.52152,13.05,3.65,0.87,72.32,0.19,9.85,0,0.17
Cluster 1: 1.51618,13.53,3.55,1.54,72.99,0.39,7.78,0,0
Cluster 2: 1.51316,13.02,0,3.04,70.48,6.21,6.96,0,0
Cluster 3: 1.51625,13.36,3.58,1.49,72.72,0.45,8.21,0,0
Missing values globally replaced with mean/mode
Final cluster centroids:
             Cluster#
                                  2
Attribute Full Data
                      0
                            1
                                         3
        (214.0) (40.0) (46.0)
                                (2.0) (126.0)
______
==
RI
         1.5184 1.5182 1.5194
                                  1.5132 1.5181
Na
         13.4079 13.0907
                           13.937
                                     13.01 13.3217
         2.6845
                  3.4073
                           0.1539
                                      0
                                         3.4216
Mg
                 1.2765 1.7778
                                          1.3517
Αl
         1.4449
                                   3.03
```

Si	72.6509	72.6908	72.9291	70.59	72.5694
K	0.4971	0.512	0.218	6.21	0.5035
Ca	8.957	8.7575	10.1867	6.945	8.6033
Ва	0.175	0.0253	0.6628	0	0.0473
Fe	0.057	0.219	0.0411	0 0	0.0123

Time taken to build model (full training data): 0.01 seconds

=== Model and evaluation on training set ===

Clustered Instances

- 0 40 (19%)
- 1 46 (21%)
- 2 2 (1%)
- 3 126 (59%)

